



UNIVERSIDADE FEDERAL DE SERGIPE
CENTRO DE CIÊNCIAS EXATAS E TECNOLOGIA
DEPARTAMENTO DE ENGENHARIA DE PRODUÇÃO



SILLAS TEIXEIRA GONZAGA

**MULTIPLE AUTOMATIC FORECAST SELECTION (MAFS):
PROPOSTA DE SISTEMA DE AUTOMAÇÃO DE PREVISÃO DE
DEMANDA**

TRABALHO DE CONCLUSÃO DE CURSO

São Cristóvão

2016



UNIVERSIDADE FEDERAL DE SERGIPE
CENTRO DE CIÊNCIAS EXATAS E TECNOLOGIA
DEPARTAMENTO DE ENGENHARIA DE PRODUÇÃO



SILLAS TEIXEIRA GONZAGA

MULTIPLE AUTOMATIC FORECAST SELECTION (MAFS):
PROPOSTA DE SISTEMA DE AUTOMAÇÃO DE PREVISÃO DE
DEMANDA

Trabalho de Conclusão do Curso de Graduação em Engenharia de Produção do Centro de Ciências Exatas e Tecnologia da Universidade Federal de Sergipe, como requisito parcial à obtenção do título de bacharel em Engenharia de Produção.

Orientador: Pedro Felipe de Abreu
Coorientador: Emerson Cleister Lima Muniz

São Cristóvão
2016

SILLAS TEIXEIRA GONZAGA

MULTIPLE AUTOMATIC FORECAST SELECTION (MAFS):
PROPOSTA DE SISTEMA DE AUTOMAÇÃO DE PREVISÃO DE
DEMANDA

Esse documento foi julgado adequado como requisito parcial à obtenção do título de bacharel em Engenharia de Produção e aprovado em sua forma final.

São Cristóvão, 06 de Dezembro de 2016

BANCA EXAMINADORA:

Emerson Cleister Lima Muniz, MSc.
Universidade Federal de Sergipe
Professor Coorientador

Reynaldo Chile Palomino, Dr.
Universidade Federal de Sergipe
Membro da banca examinadora

Suzana Leitão Russo, Dr.
Universidade Federal de Sergipe
Membro da banca examinadora

AGRADECIMENTOS

Agradeço à minha família e às minhas tias Eliana e Cinelange por serem terem apoiados os meus estudos.

Aos grandes amigos que fiz em quase seis anos de graduação pelo companheirismo e pelos sempre divertidos trabalhos em equipe. A graduação foi mais fácil ao lado de vocês.

Aos professores Pedro Felipe de Abreu, Celso Sakuraba e Emerson Muniz pelos conselhos não só acadêmicos mas também pessoais que serão de grande importância para mim.

Agradeço a Rafael Magnani não só por me ajudar a obter os dados que tornaram esta monografia possível mas também pelo apoio à minha ideia e pelos ensinamentos profissionais.

RESUMO

Previsão de demanda é a atividade que consiste em obter valores de vendas de um determinado produto para um período no futuro baseado em seu histórico de vendas e em outros tipos de dados. A previsão pode ser obtida por métodos qualitativos, como a opinião de gerentes e especialistas da área, ou por quantitativos, pela aplicação de modelos estatísticos. Previsões de demanda com boa acurácia resultam no equilíbrio entre oferta e demanda, sem causar prejuízo por sobras ou por faltas. Contudo, quando se deseja realizar milhares de previsões de demanda periodicamente, surge a necessidade de uma solução que seja não só precisa mas também automatizada. O presente trabalho consiste na elaboração de um sistema de previsão de demanda denominado *Multiple Automatic Forecast Selection* (MAFS) que mensura a acurácia de dezoito modelos de previsão de demanda disponíveis na linguagem de programação R para uma dada série temporal e seleciona automaticamente o de maior precisão para prever os valores futuros para a série. O sistema foi testado com dados de vendas mensais de produtos de uma distribuidora de bebidas na região Nordeste entre Janeiro de 2015 a Agosto de 2016. Os resultados de acurácia obtidos pelo sistema para a simulação realizada, com as séries disponíveis, foram melhores que os dos métodos utilizados pela empresa, o que indica que o sistema proposto tem potencial para ser utilizado pela empresa e por outras para a atividade rotineira de previsão de demanda.

Palavras-chave: Previsão de demanda; Métricas de erro; Linguagem R; Indústria de bebidas.

ABSTRACT

Demand forecasting consists in obtaining future sales values for a given product based on its historical sales and other kinds of data. The forecast can be obtained by methods either qualitative, such as the opinion of managers or business specialists, or quantitative, through statistical models. The result of accurate forecasts is the supply and demand equilibrium, without great monetary losses caused by neither surplus nor lack of products. However, when one desires to forecast hundreds or even thousands of different time series periodically, there must exist a solution that is not only accurate but also automated. This work consists in the development of a demand forecast system called Multiple Automatic Forecast Selection (mafs) which measures the accuracy of eighteen different forecast models available on the R programming language given a time series as input and automatically selects the one with the lowest error to forecast future values. This system was tested with monthly sales data of products sold by a brewing company in Brazil's Northeast region. The data range from January of 2015 to August of 2016. The accuracy obtained by the developed system for the time series used during this work is better than the forecast methods officially used by the own company, which shows that the proposed system has potential to be used by the company and others to routinely forecast time series.

Keywords: Demand forecasting; Error metrics; R programming language; Brewing industry.

SUMÁRIO

1. INTRODUÇÃO	12
1.1 Objetivos	12
1.1.1 Objetivos Gerais	12
1.1.2 Objetivos Específicos	13
1.2 Justificativa	13
1.3 Estrutura do trabalho.....	13
2 REFERENCIAL TEÓRICO	15
2.1 Introdução à previsão de demanda.....	15
2.2 Séries temporais	16
2.2.1 Decomposição de Séries Temporais	17
2.3 Métodos Qualitativos	19
2.4 Métodos Quantitativos complexos	20
2.4.1 Modelos ARIMA	20
2.4.2 Suavização exponencial	21
2.4.3 Redes neurais artificiais	22
2.4.4 BATS e TBATS	23
2.4.5 Suavização por splines cúbicas	24
2.4.6 Método Theta	25
2.4.7 Modelo de Croston	26
2.4.8 Regressão	28
2.5 Métodos Quantitativos simples.....	29
2.5.1 Modelo da Média Simples	30
2.5.2 Modelo ingênuo	31
2.5.3 Modelo sazonal ingênuo	31

2.5.4 Modelo de passeio aleatório	31
2.6 Métricas de acurácia para seleção de modelo	31
2.6.1 Erros dependentes da escala	32
2.6.2 Erros percentuais	33
2.7 Intervalos de predição	33
2.8 Estratégia de criação de modelo de previsão	34
3. PROCEDIMENTOS METODOLÓGICOS	35
4. DESCRIÇÃO DO SISTEMA PROPOSTO	37
5. RESULTADOS DA SIMULAÇÃO	39
5.1 Análise exploratória	39
5.2 Exemplo de aplicação do sistema	40
5.3 Resultados do sistema proposto	43
5.3.1 Resultados gerais	43
5.3.2 Resultados agregados por produto	46
5.3.3 Resultados agregados por centro de distribuição	47
5.3.4 Resultados totais agregados por mês	49
5.4 Resultados dos modelos usados no sistema	50
6 CONCLUSÃO	51
REFERÊNCIAS BIBLIOGRÁFICAS	52
APÊNDICE A – CÓDIGO DO SISTEMA CRIADO	56
APÊNDICE B – AJUSTE DE MODELOS NA SÉRIE TEMPORAL DO PRODUTO P001	59

LISTA DE FIGURAS

Figura 1 - Exemplo de tendência e sazonalidade de uma série temporal.	17
Figura 2 – Exemplos de séries de passeio aleatório.....	19
Figura 3 - Exemplo de previsão realizada com método Theta.	26
Figura 4 - Ilustração do funcionamento do algoritmo de seleção de modelo de previsão.	37
Figura 5 – Série histórica do volume de vendas da região Nordeste.....	39
Figura 6 – Curva ABC dos produtos vendidos na região Nordeste.....	40
Figura 7 – Série histórica do produto de maior demanda.....	41
Figura 8 – Erro absoluto médio e intervalo de confiança dos métodos de previsão avaliados	44
Figura 9 – Resultados dos modelos de previsão usados no sistema.....	50
Figura 10 - Ajuste e previsão obtidos pelo método ARIMA.....	59
Figura 11 – Ajuste e previsão obtidos pelo método de suavização exponencial.....	59
Figura 12 – Ajuste e previsão obtidos pelo método de redes neurais.....	60
Figura 13 - Ajuste e previsão obtidos pelo método TBATS	60
Figura 14 - Ajuste e previsão obtidos pelo método BATS	61
Figura 15 – Ajuste e previsão obtidos pelo modelo estrutural	61
Figura 16 – Ajuste e previsão obtidos pelo modelo da média simples.....	62
Figura 17 – Ajuste e previsão obtidos pelo modelo ingênuo.....	62
Figura 18 – Ajuste e previsão obtidos pelo modelo sazonal ingênuo.....	63
Figura 19 – Ajuste e previsão obtidos pelo modelo do passeio aleatório.....	63
Figura 20 – Ajuste e previsão obtidos pelo modelo do passeio aleatório com deriva..	64
Figura 21 – Ajuste e previsão obtidos pelo modelo das splines cúbicas.	64
Figura 22 – Ajuste e previsão obtidos pelo modelo Theta	65
Figura 23 - Ajuste e previsão obtidos pelo modelo Croston	65
Figura 24 - Ajuste e previsão obtidos pelo modelo de regressão	66
Figura 25 - Ajuste e previsão obtidos pelo modelo híbrido.....	66

LISTA DE QUADROS

Quadro 1 – Possíveis modelos de suavização exponencial	22
Quadro 2 - Modelos de previsão utilizados no trabalho	38

LISTA DE TABELAS

Tabela 1 – Erros obtidos pelos métodos de previsão.....	42
Tabela 2 – Comparação do erro de previsão para o produto P001	43
Tabela 3 – Resultados gerais do sistema proposto comparados com os métodos da empresa.....	44
Tabela 4 – Resultados do teste ANOVA	45
Tabela 5 – Resultados do teste de Tukey.....	46
Tabela 6 – Resultados agregados para o produto P001	46
Tabela 7 – Pontuação agregada por produto dos métodos de previsão	47
Tabela 8 – Erro absoluto agregado por produto dos métodos de previsão	47
Tabela 9 – Resultados agregados para o centro de distribuição C01.....	48
Tabela 10 – Pontuação agregada por centro de distribuição dos métodos de previsão	48
Tabela 11 - Erro absoluto agregado por centro de distribuição dos métodos de previsão	48
Tabela 12 - Erro absoluto agregado por mês dos métodos de previsão.....	49

LISTA DE SIGLAS

ARIMA	Modelo Autorregressivo Integrado de Média Móvel.
BATS	Transformação Box-Cox, erros ARMA e componentes Tendência e Sazonalidade.
CD	Centro de distribuição
MAE	Erro absoluto médio
MAFS	Múltipla seleção automática de previsão
MAPE	Erro porcentual absoluto médio
RMSE	Raiz do erro quadrático médio
TBATS	Transformação trigonométrica Box-Cox, erros ARMA e componentes Tendência e Sazonalidade.

1. INTRODUÇÃO

Em um cenário de alta competitividade no mercado como se observa na atualidade, é natural que as empresas busquem constantemente otimizar suas estratégias para atender às necessidades dos clientes com investimentos baseados em previsões eficazes de demanda. Assim, é necessário tomar decisões que resultem no equilíbrio entre oferta e demanda, sem causar prejuízo por perdas (oferta maior que demanda) ou por demanda não aproveitada (oferta menor que demanda).

Previsão de demanda é a atividade que consiste em obter valores de vendas de um determinado produto para um período no futuro. Pode ser feito quantitativamente, por meio da aplicação de algoritmos simples ou complexos, ou qualitativamente, através da opinião de especialistas.

Previsões são realizadas nos mais diversos ambientes além de empresas, como nos setores econômico, agropecuário e energético. Previsões cujas acurácias são satisfatórias podem ajudar um país a planejar cenários, uma fornecedora de energia eólica a se preparar para diferentes níveis de força do vento um pequeno agricultor a preparar sua colheita em função da chuva (ROUDIER, DUCHARNE e FEYEN, 2014).

O avanço tecnológico das últimas décadas possibilitou para as companhias o registro histórico de dados das mais diversas naturezas, dentre eles as séries históricas de vendas de seus produtos. Adicionalmente, o uso de linguagens de programação gratuitas utilizadas, entre outros, para fins analíticos, como as linguagens Python (ROSSUM, 1995) e R (R CORE TEAM, 2016), tornou simples a aplicação de algoritmos estatísticos avançados para processos de previsão em larga escala de maneira automatizada. Empresas de grande porte, que precisam fazer dezenas de milhares de previsões periodicamente, podem ser enormemente beneficiados por esses avanços.

1.1 Objetivos

1.1.1 Objetivos Gerais

Desenvolver um sistema para automatizar a escolha do melhor método de previsão

para uma dada série temporal.

1.1.2 Objetivos Específicos

- Realizar uma revisão bibliográfica de modelos quantitativos de previsão de demanda implementados na linguagem de programação R;
- Automatizar a seleção do melhor modelo previsão para mais de 7.000 séries temporais históricas de vendas de produtos da empresa analisada;
- Simular o desempenho do sistema proposto e o comparar com as previsões realizadas pela empresa estudada.

1.2 Justificativa

O desempenho de uma previsão afeta diretamente a gestão do estoque de uma organização e, caso feita erroneamente, pode acarretar em prejuízos financeiros com vencimentos de produtos ou operacionais com a superlotação física do estoque (previsão superestimada) ou com a perda de clientes para a concorrência em decorrência do não-aproveitamento da demanda (previsão subestimada).

Além disso, uma mesma previsão pode tomar um grande tempo de análise exploratória de dados, ajuste de parâmetros e a aplicação de diversos modelos. Em um cenário onde é necessário realizar milhares de previsões periodicamente, esse procedimento é inviável. Por isso, um sistema de previsão deve ser não apenas eficiente mas também automatizado, isto é, capaz de fornecer uma boa eficiência de acurácia sem interferência humana.

1.3 Estrutura do trabalho

No capítulo 1, Introdução, o tema da previsão de demanda e sua importância, além da justificativa e da problemática do trabalho, são discutidos.

O capítulo 2, Referencial Teórico traz uma revisão bibliográfica sobre os principais conceitos necessários para o entendimento do trabalho, como os modelos quantitativos estudados e a métrica de erro utilizada para a seleção do melhor modelo.

O capítulo 3, Procedimentos Metodológicos descreve a empresa cujos dados foram usados para a simulação dos resultados e o processo de coleta dados.

O capítulo 4, Descrição do Sistema Proposto, explica o passo-a-passo do algoritmo criado e justifica a escolha da métrica de erro usada para a seleção do melhor modelo de previsão.

O capítulo 5, Discussão, apresenta dados de vendas da empresa e de seus produtos e os resultados obtidos da previsão de demanda.

O capítulo 6, Conclusão encerra o trabalho, apresentando ensinamentos obtidos em seu desenvolvimento além de outras considerações finais.

2 REFERENCIAL TEÓRICO

2.1 Introdução à previsão de demanda

A atividade de previsão de demanda é realizada em diversos segmentos de negócios e amplamente usada por tomadores de decisões. Em Economia, governos, empresas, bancos e empresas de consultoria econômica rotineiramente projetam valores de diversos indicadores macroeconômicos, como o Produto Interno Bruto, desemprego e inflação. (DIEBOLD, 2015).

Estratégias de negócio em torno de previsões de vendas são tomadas o tempo todo e envolvem todas as partes da empresa, como gestão de operações (aumento ou redução da mão-de-obra, produção, estoque, investimentos), *marketing* (precificação, publicidade) e contabilidade (balanços que usam previsões de receitas e despesas). Organizações em geral tomam usam previsões para decidir o que produzir, quando produzir, quanto produzir e em quanto se deve aumentar a capacidade de produção. (DIEBOLD, 2015).

Pequenos agricultores se beneficiam de saber a previsão do tempo para os dias, semanas ou meses seguintes. Em um estudo em Senegal, a introdução de previsões sazonais de clima a uma comunidade de agricultores familiares afetou as decisões de 75% dos agricultores entrevistados, evidenciando que as previsões têm potencial para ajudar os fazendeiros a se adaptar a mudanças climáticas e também a se beneficiar financeiramente da antecipação de condições de clima favoráveis (ROUDIER, DUCHARNE e FEYEN, 2014).

Segundo Hyndman e Athanasopoulos (2012), existem seis elementos básicos que todos os praticantes de previsão deveriam conhecer:

- Previsão é um problema estocástico;
- Todas as previsões estão erradas;
- Algumas previsões são úteis;
- Todas as previsões podem ser melhoradas;
- Precisão nunca é garantida;
- Ter uma segunda opinião é preferível.

2.2 Séries temporais

Quando uma variável é medida e registrada sequencialmente em tempo durante ou em um intervalo fixo, chamado de intervalo amostral, os dados resultantes são chamados de série temporal. Observações coletadas em um intervalo amostral no passado recebem o nome de série temporal histórica e são usadas para analisar e entender o passado e para prever o futuro, permitindo que gestores e executivos tomem decisões respaldadas em informações confiáveis (COWPERTWAIT e METCALFE, 2009).

Séries temporais possuem três tipos de padrões, também chamados de componentes (HYNDMAN e ATHANASOPOULOS, 2012):

- Tendência: ocorre quando a variável da série temporal apresenta um aumento ou diminuição de longo prazo;
- Sazonalidade: corresponde a um padrão fixo que se repete no mesmo período de tempo (Ex.: aumento das vendas de roupa de praia no verão);
- Ciclos: ocorre quando os dados mostram subidas e quedas que não possuem um período fixo;
- Erro aleatório: diz respeito aos movimentos irregulares explicados por causas desconhecidas.

Hyndman e Athanasopoulos (2012) afirmam que podemos pensar em uma série temporal como uma função y_t composta pelos três elementos descritos acima. Se a série temporal for descrita como um modelo aditivo, podemos escrever:

$$Y_t = S_t + T_t + E_t \quad (1)$$

onde Y_t é o valor original da série temporal no período t , S_t é o componente sazonal, T_t o componente de tendência e E_t o erro aleatório.

Por outro lado, se a série temporal for descrita como um modelo multiplicativo, temos:


$$Y_t = S_t \times T_t \times E_t \quad (2)$$

Uma série temporal de N observações sucessivas $z = (z_1, z_2, \dots, z_N)$ é uma amostra de uma população infinita de amostras do tipo que poderiam ter sido geradas pelo processo a que ela diz respeito. Assim como em outros tipos de investigação estatística, o objetivo principal da previsão é inferir propriedades da população a partir de uma amostra.


A Figura 1 mostra exemplos de séries temporais com tendência, sazonalidade e ciclo.

Figura 1 - Exemplo de tendência e sazonalidade de uma série temporal.


- a) Padrão de demanda regular com variação aleatória, sem tendência e sem elementos sazonais.




- b) Padrão de demanda regular com variação aleatória e com tendência, mas sem elementos sazonais.



- c) Padrão de demanda regular com variação aleatória, com tendência e elementos sazonais.



- d) Padrão de demanda irregular.



Fonte: Silva e D'Agosto (2012)

2.2.1 Decomposição de Séries Temporais

As técnicas de decomposição têm como objetivo isolar os diferentes componentes de uma série temporal, como a tendência, a sazonalidade e padrões cíclicos. Apesar de não terem sido criadas como ferramentas de previsão, é comum decompor uma série temporal antes de a modelar com um modelo preditivo, visto que os elementos decompostos são mais fáceis de serem extrapolados devido às suas naturezas determinísticas, principalmente em séries com altos níveis de ruído (THEODOSIOU, 2011).

➤ Método STL

STL, um dos existentes métodos de decomposição, é um acrônimo para Decomposição de Sazonalidade e Tendência usando Loess, sendo este um método de estimação de relacionamentos não-lineares. Consegue lidar com qualquer tipo de sazonalidade (não somente mensal e trimestral) e possui um tratamento robusto de anomalias. Foi criado

para atender a seis objetivos:

- Algoritmo simples e de uso fácil e direto;
- Flexibilidade na especificação da quantidade de variação dos componentes de tendência e sazonalidade;
- Especificação do número de observações por ciclo do componente sazonal para um inteiro maior que um;
- A habilidade de decompor séries com valores ausentes;
- Componentes de tendência e sazonalidade que não são distorcidos por comportamentos anômalos dos dados;
- Fácil implementação computacional, mesmo para séries longas.

Sua formulação matemática completa está presente em Cleveland *et al.* (1990).

➤ **Método do modelo estrutural de Harvey**

Os modelos de séries temporais estruturais foram desenvolvidos por Harvey e Peters (1990) e também define a composição de uma série como tendência, sazonalidade e ruído. Contudo, ele é menos rígido que o modelo clássico de decomposição pois permite que os componentes de tendência e sazonalidade evoluam (variem) aleatoriamente ao invés de deterministicamente. (BROCKWELL e DAVIS, 1996).

Por exemplo, um modelo estrutural simples é obtido adicionando ruído em uma série do tipo passeio aleatório (não-sazonal) ou *random walk* (Ver seção 3.5.4). O modelo clássico de decomposição é dado pela Equação (3).

$$Y_t = M_t + W_t \quad (3)$$

onde $\{W_t\} \sim WN(0, \sigma_w^2)$ e $M_t = m_t$ é o nível ou sinal determinístico no tempo t . A notação $WN(0, \sigma^2)$ denota um tipo de série temporal chamada de ruído branco (*white noise*), que é uma sequência de variáveis aleatórias não-correlacionadas com média 0 e variância σ^2 .

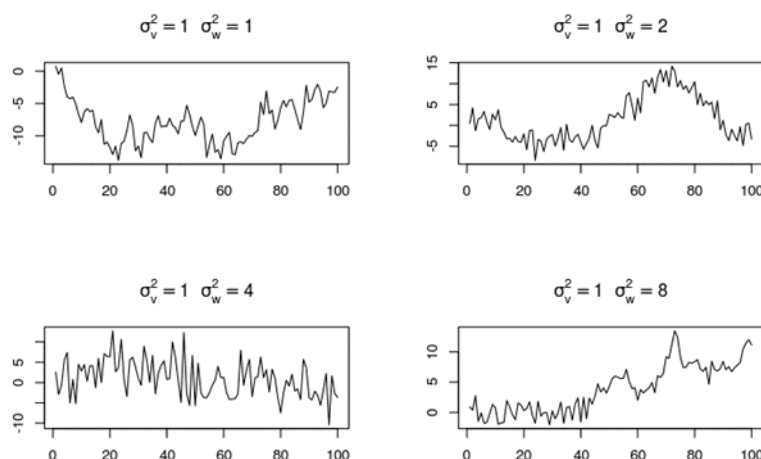
Pode-se adicionar aleatoriedade no nível supondo que M_t é um passeio aleatório expresso pela Equação (4).

$$M_{t+1} = M_t + V_t; V_t \sim WN(0, \sigma_v^2) \quad (4)$$

A Figura 2 mostra quatro simulações de modelos de passeio aleatório com ruído

branco para diferentes combinações de valores das variâncias.

Figura 2 – Exemplos de séries de passeio aleatório



Fonte: Autoria própria.

2.3 Métodos Qualitativos

De acordo com Hyndman e Athanasopoulos (2012), se não há dados disponíveis ou se os dados disponíveis são irrelevantes para a previsão, métodos qualitativos de previsão devem ser usados. Mais do que um exercício de adivinhação, existem métodos bem desenvolvidos e estruturados para obter previsões sem séries históricas.

Lawrence *et al.* (2006) observa que, embora métodos qualitativos sejam pensados como inimigos da precisão, as previsões em forma de julgamento ou opinião já eram reconhecidas na época como componentes indispensáveis da previsão, atraindo a atenção de pesquisadores para melhor entender e melhorar o seu uso. Apenas nesse trabalho, mais de 200 referências são mencionadas.

Lee, Song e Mjelde (2008) mostram como um modelo de previsão qualitativa, elaborado pelo método Delphi, pode ser utilizado para prever eventos sem precedentes como uma feira internacional de turismo devido à falta de dados históricos. Nesses casos, é possível combinar técnicas quantitativas com questionários aplicados a eventuais turistas.

Contudo, é necessário alertar sobre os perigos e limitações dos julgamentos em previsões (HYNDMAN e ATHANASOPOULOS, 2012), como. Um deles é a inconsistência, pois, ao contrário de modelos estatísticos que são gerados por equações matemáticas imutáveis, opiniões podem ser afetadas por limitação de memória, agendas políticas, má-fé, falta de atenção, otimismo ou pessimismo ou até mesmo fatores psicológicos.

2.4 Métodos Quantitativos complexos

Métodos quantitativos podem ser aplicados quando três condições são satisfeitas (MAKRIDAKIS, WHEELWRIGHT e HYNDMAN, 1997):

1. Informação sobre o passado está disponível;
2. Essa informação pode ser quantificada em forma de dados numéricos;
3. Pode ser assumido que padrões passados continuarão no futuro.

A maior parte da fundamentação teórica sobre os diversos modelos de previsão existentes pode ser encontrada em Hyndman e Athanasopoulos (2012).

2.4.1 Modelos ARIMA

ARIMA é uma sigla em inglês que significa Modelo Autorregressivo Integrado de Média Móvel. Modelos ARIMA foram popularizados por George Box e Gwilym Jenkins na década de 1970 e são até o presente um dos métodos de previsão mais populares entre pesquisadores e praticantes, além dos modelos de suavização exponencial.

Segundo Wheelwright e Makridakis (1985), existem três parâmetros que são capazes de representar uma série temporal estacionária (uma série temporal cujas propriedades não dependem do tempo): um modelo autorregressivo (AR), modelo de médias móveis (MA) e o modelo combinado entre autoregressivo e de médias móveis (ARMA).

O método de Box e Jenkins busca um modelo ARIMA que seja capaz de entender o processo estocástico por meio do qual a série temporal é gerada. A Equação (5) mostra a definição formal de um modelo ARIMA.

$$w_t = \phi_1 w_{t-1} + \dots + \phi_p w_{t-p} + e_t - \theta_1 e_{t-1} - \dots - \theta_q e_{t-q} \quad (5)$$

onde:

$$w_t = x_t + x_{t-d}$$

ϕ_p é o parâmetro de ordem p do modelo AR.

θ_q é o parâmetro de ordem q do modelo MA.

e_t é o erro aleatório no tempo t.

d equivale ao grau de homogeneidade não estacionária.

A estimação dos parâmetros p, d e q do modelo ARIMA pode ser realizada automaticamente pelo pacote *forecast*, disponível gratuitamente por meio da linguagem de programação R. Os detalhes de como o algoritmo funciona estão disponíveis em Hyndman e Khandakar (2008).

2.4.2 Suavização exponencial

Modelos de suavização exponencial foram propostos na década de 1950 por Brown (1959), Holt (1957) e Winters (1960) e consistem em usar médias ponderadas de observações passadas para prever valores futuros, considerando ou não a tendência e a sazonalidade da série temporal. Quanto mais recente o valor observado, maior o seu peso.

Existem diferentes versões de modelos de suavização exponencial. Por exemplo, a suavização exponencial simples é definida pela Equação (6).

$$\hat{y}_{T+1|T} = \alpha y_T + \alpha(1 - \alpha)y_{T-1} + \alpha(1 - \alpha)^2 y_{T-2} + \dots \quad (6)$$

onde α é o parâmetro de suavização do modelo e está definido entre 0 (zero) a 1 (um). Quanto mais próximo de 1, maior o peso a observações recentes.

Se realizarmos variações nos parâmetros de tendência e sazonalidade da série temporal, é possível obter 15 diferentes modelos de suavização exponencial. Uma explicação da formulação matemática e das hipóteses de outros métodos de suavização exponenciais como o Método Linear de Holt, Método de Tendência Exponencial, Método sazonal Holt-Winters, etc., podem ser encontrados em Gardner (1985) e Taylor (2003). Os possíveis modelos de suavização exponencial são listados no Quadro 1.

Quadro 1 – Possíveis modelos de suavização exponencial

Tendência	Sazonalidade		
	N (nenhum)	A (aditiva)	M (multiplicativa)
N (nenhum)	(N, N)	(N, A)	(N, M)
A (aditiva)	(A, N)	(A, A)	(A, M)
A _d (aditiva amortecida)	(A _d , N)	(A _d , A)	(A _d , A)
M (multiplicativa)	(M, N)	(M, A)	(M, M)
M _d (multiplicativa amortecida)	(M _d , N)	(M _d , A):	(M _d , M)

Fonte: Hyndman e Athanasopoulos (2012)

Cada método apresentado no Quadro 1 é categorizado de acordo com o tipo dos componentes de tendência e de sazonalidade. Por exemplo, o método (N, N) corresponde à suavização exponencial simples e o método (M, N) à suavização exponencial de tendência.

Todos esses modelos consistem de uma equação de mensuração que descrevem os dados e equações de transição que descrevem como os componentes - também chamados por Hyndman Athanasopoulos (2012) de estados – de tendência e sazonalidade variam com o tempo. Por isso, podem ser chamados de modelos de estado espaço.

O processo de modelagem de cada um desses 15 métodos para uma mesma série temporal seria muito difícil. Para isso, um algoritmo que automatiza o processo de estimação dos parâmetros de tendência e sazonalidade foi criado por Hyndman *et al.* (2002), e está disponível gratuitamente no pacote *forecast*, da linguagem de programação R, pode ser usado para automatizar o processo de estimação dos parâmetros.

2.4.3 Redes neurais artificiais

Redes neurais artificiais são métodos de previsão baseados em modelos matemáticos do cérebro humano. Permitem relacionamentos não-lineares complexos entre a variável dependente e a independente.

Uma rede neural pode ser interpretada como uma rede de neurônios organizados em camadas. Os preditores ou *inputs* formam a camada de baixo e as previsões ou *outputs* formam a camada de cima. As camadas intermediárias, que podem existir ou não, são chamadas de ocultas.

Cada preditor tem um coeficiente associado a ele, chamado de peso. Inicialmente, os pesos atribuídos aos inputs são valores aleatórios que são atualizados a medida em que a rede neural utiliza um algoritmo de aprendizagem para minimizar uma função de custo do modelo, que corresponde a uma métrica de erro.

O tipo mais utilizado de rede neural é o *feedforward*, onde os neurônios são dispostos geralmente em duas camadas ativas e só se conectam com os de camadas subsequentes (CALOBA, CALOBA e SALIBY, 2002).

Redes neurais já são largamente usadas em previsão de demanda, como nos seguintes trabalhos:

- Caloba, Caloba e Saliby (2002), para a previsão de demanda de cerveja na Austrália;
- Branco e Sampaio (2008), para a previsão de demanda de equipamentos de infraestrutura de telecomunicações;
- Kaastra e Boyd (1996) para séries temporais econômicas e financeiras;
- Claveria e Torra (2014) para a demanda turística na Catalunha;
- Lima (2015) para a irradiação de raios solares na região Nordeste do Brasil.

2.4.4 BATS e TBATS

Com o objetivo de modelar séries temporais que apresentam uma grande variedade de padrões sazonais, Livera et al (2010) propuseram os métodos BATS e TBATS.

BATS é uma sigla para Transformação **B**ox-Cox, erros **A**RMA e componentes **T**endência e **S**azonalidade. Pode ser representado matematicamente como:

$$\begin{aligned}
 y_t^{(w)} &= \begin{cases} (y_t^\omega - 1)/\omega, & \omega \neq 0 \\ \log y_t, & \omega = 0 \end{cases} \\
 y_t^{(\omega)} &= S_{(t-1)} + \phi T_{t-1} + \sum W_{t-s_i}^{(i)} + d_t \\
 S_t &= S_{(t-1)} + \phi T_{t-1} + \alpha d_t \\
 T_t &= (1 - \phi)T + \phi T_{t-1} + \beta d_T \\
 W_t^{(i)} &= W_{t-s_i}^{(i)} + \gamma_i d_t \\
 d_t &= \sum \phi_i d_{t-i} + \sum \varepsilon_{t-1} + \varepsilon_t
 \end{aligned} \tag{7}$$

onde ω é o parâmetro para a transformação de Box-Cox, ϕ representa o componente de amortização da tendência que convergirá para T, α e β são os parâmetros de suavização para o nível e a tendência locais, s_1, s_2, \dots, s_n são os múltiplos ciclos sazonais, $\gamma_1, \gamma_2, \dots, \gamma_n$ são os

parâmetros de suavização exponencial, d_t é um processo ARMA(p, q) e ε é uma variável gaussiana com média zero e variância σ^2 constante.

Já o método TBATS é uma classe de modelo de inovação estado espaço obtida pela representação de componentes sazonais como uma formulação sazonal trigonométrica, permitindo, assim modelar períodos sazonais decimais. Sua formulação matemática consiste em:

$$\begin{aligned} s_t^{(i)} &= \sum s_{j,t}^{(i)} \\ s_{j,t}^{(i)} &= s_{j,t-1}^{(i)} \cos \lambda_j^{(i)} + s_{j,t-1}^{*(i)} \sin \lambda_j^{(i)} + \gamma_1^{(i)} d_t \\ s_{j,t}^{*(i)} &= -s_{j,t-1}^{(i)} \sin \lambda_j^{(i)} + s_{j,t-1}^{*(i)} \cos \lambda_j^{(i)} + \gamma_2^{(i)} d_t \end{aligned} \quad (8)$$

onde $\gamma_1^{(i)}$ e $\gamma_2^{(i)}$ são parâmetros de suavização, $\lambda_j^{(i)} = 2\pi j/m_i$, $s_{j,t}^{(i)}$ o nível estocástico do i -ésimo componente sazonal, $s_{j,t}^{*(i)}$ o crescimento estocástico do i -ésimo componente sazonal usado para descrever a mudança do componente sazonal ao longo do tempo e k_i a quantidade de harmônicas requeridas.

Existem na literatura aplicações de modelos BATS e TBATS em séries temporais de trânsito de veículos (CUI e GUO, 2015) e receitas financeiros de um hotel (PEREIRA, 2016). Leitores interessados podem conhecer a formulação matemática desses dois métodos por inteiro em Livera, Hyndman e Snyder (2010). O pacote *forecast*, utilizado por meio da linguagem de programação R, torna fácil o processo de estimação dos parâmetros.

2.4.5 Suavização por *splines* cúbicas

Segundo Domingues (2014), *splines* cúbicas são funções polinomiais contínuas por partes e de grau menor ou igual a 3 em cada uma delas. Cada parte $y_k(x)$ está definida no intervalo $[x_{k-1}, x_k]$, onde k é um número inteiro positivo. A suavização na transição entre nós é garantida pelo fato de as derivadas de primeira e segunda ordens da função serem contínuas, evitando picos sejam formados. Além disso, a função *spline* permite a interpolação de curvas suaves com baixa probabilidade de exibir as grandes oscilações características de funções polinomiais de ordem elevada (ANDRIOLO, 2006).

Sejam $f(x_i)$ as imagens de uma função desconhecida $f(x)$ para $(n + 1)$ valores de x_i

com $i = 0, 1, 2, \dots, n$. A função Y_3 será chamada de *spline* cúbica interpolante de $f(x)$ se existirem n polinômios de grau menor ou igual a 3, denotados por $y_k(x)$ que satisfaçam cinco condições C1, C2, C3, C4 e C5, de acordo com a Equação (9).

$$\begin{aligned} C1: Y_3(x) &= y_k(x) \text{ para } x \in [x_{k-1}, x_k], k = 1, 2, \dots, n \\ C2: Y_3(x_i) &= f(x_i), i = 0, 1, 2, \dots, n \\ C3: y_k(x_k) &= y_{k+1}(x_k), k = 1, 2, \dots, (n-1) \\ C4: y'_k(x_k) &= y'_{k+1}(x_k), k = 1, 2, \dots, (n-1) \\ C5: y''_k(x_k) &= y''_{k+1}(x_k), k = 1, 2, \dots, (n-1) \end{aligned} \quad (9)$$

No contexto de séries temporais, a suavização por *splines* cúbicas pode ser definida como a função $\hat{f}(t)$ que minimiza a Equação (10) para todas as funções que possuem uma derivada de segunda ordem f em S onde $[1, n] \subseteq S \subseteq \mathbb{R}$.

$$\sum (y_t - f(t))^2 + \lambda \int (f''(u))^2 du \quad (10)$$

λ corresponde à taxa de suavização que, quanto maior o valor para esse parâmetro, maior a proximidade entre $\hat{f}(t)$ e uma função linear.

Métodos para a extrapolação linear de uma tendência estocástica baseado em suavização por *splines* cúbicas e para a estimação do parâmetro λ são discutidos em Hyndman *et al.* (2005).

2.4.6 Método Theta

Assimakopoulos e Nikopoulos (2000) propuseram um método baseado em modificar a curvatura local de uma série temporal através de um coeficiente representado pela letra grega “Theta” (θ). As novas séries criadas, chamadas de linhas-Theta, mantêm a média e a inclinação da série original mas não suas curvaturas. O método, portanto, decompõe a série original em duas ou mais linhas-Theta, que são extrapoladas separadamente e têm suas previsões combinadas para formar os valores futuros fornecidos pelo modelo.

Em vez de apenas decompor uma série temporal nos elementos conhecidos na literatura (tendência, sazonalidade, ciclos e erro aleatório), o método Theta decompõe também a série sazonalmente ajustada em componentes de curto e longo prazo.

O coeficiente Theta, obtido por meio de um problema de minimização descrito em

Assimakopoulos e Nikopoulos (2000), é aplicado às segundas diferenças da série temporal original, denotada X , para criar novas séries, como mostra a Equação (11).

$$X''_{nova}(\theta) = \theta X'', \text{ onde } X'' = X_t - 2X_{t-1} + X_{t-2} \quad (11)$$

A combinação de linhas-Theta $\theta = 0$ e $\theta = 2$ foi empregada pelos autores para produzir previsões para séries temporais incluídas na competição M3. Assim, a decomposição da série corresponde à Equação (12).


$$X_t = \frac{1}{2}(L(\theta = 0) + L(\theta = 2)), \text{ onde:} \quad (12)$$

$$L(\theta = 0) = \text{regressão linear dos dados}$$

$$L(\theta = 2) = 2X_t - L(\theta = 0)$$

Um exemplo de modelo criado com essas duas linhas-Theta é mostrado na Figura 3.

Figura 3 - Exemplo de previsão realizada com método Theta.



Fonte: Assimakopoulos e Nikopoulos (2000)

2.4.7 Modelo de Croston

O modelo de Croston foi desenvolvido como uma alternativa específica para demandas intermitentes, que são um tipo de série temporal que apresenta diversos zeros nos dados, o que prejudica a precisão de modelos de previsão tradicionais (CROSTON, 1972).

O método é baseado em aplicar separadamente uma suavização exponencial sobre a

demanda (z), estimando a demanda média futura, e outra sobre o intervalo entre demandas (p), estimando o intervalo médio futuro. Após cada ocorrência de demanda (z diferente de 0), as estimativas são atualizadas. Caso não ocorra demanda ($z = 0$) no período t , o método apenas incrementa a contagem dos períodos entre as demandas por meio da variável q (KOENIG, 2014). A formulação matemática das duas situações expostas é mostrada a seguir.

Se $y_t = 0$:

$$\begin{aligned} z'_t &= z'_{t-1} \\ p'_t &= p'_{t-1} \\ q &= q + 1 \end{aligned} \tag{13}$$

Se $y_t \neq 0$:

$$\begin{aligned} z'_t &= z'_{t-1} + \alpha(y_t - z'_{t-1}) \\ p'_t &= p'_{t-1} + \alpha(q - p'_{t-1}) \\ q &= 1 \end{aligned} \tag{14}$$

Combinando a previsão do tamanho da demanda com a previsão do intervalo entre demandas, obtém-se a equação central proposta por Croston:

$$y'_t = \frac{z'_t}{p'_t} \tag{15}$$

onde:

x_t = indicador binário de demanda no tempo t

z_t = tamanho da demanda no tempo t

$y_t = x_t \times z_t$ = demanda para um item no tempo t

p = número médio de períodos de tempo entre as demandas;

α = coeficiente de suavização;

y'_t = estimativa da demanda média para o período t

q = intervalo de tempo desde a última demanda;


O valor do coeficiente de suavização deve ser especificado, não podendo ser estimado.

Croston (1972) concluiu que os melhores resultados ocorrem para $0,1 \leq \alpha \leq 0,3$.

2.4.8 Regressão

Sejam x e y duas variáveis numéricas aleatórias. Supõe-se que y é função de x . Portanto, deseja-se encontrar uma função linear de x que melhor se ajusta aos dados, no sentido de que a soma do quadrado das distâncias verticais entre os pontos x e y até a reta de ajuste é mínima, como mostrado na Figura 4. Esse procedimento é denominado regressão e o método de estimação dos parâmetros do modelo é chamado de quadrados mínimos (DIEBOLD, 2015).

Figura 4 – Reta de ajuste de regressão



Fonte: Diebold (2015).

A regressão de séries temporais diferem de uma análise de regressão comum porque os resíduos do modelo também formam uma série temporal, apresentando uma correlação serial – isto é, o resíduo do período t é correlacionado um ou mais resíduos passados (COWPERTWAIT e METCALFE, 2009).

Um modelo de uma série temporal $\{x_t: t = 1, \dots, n\}$ é linear se puder ser expresso como:

$$x_t = \alpha_0 + \alpha_1 u_{1,t} + \alpha_2 u_{2,t} + \dots + \alpha_m u_{m,t} + z_t \quad (16)$$

onde $u_{i,t}$ é o valor do variável explanatória i no tempo t , z_t é o erro no tempo t e $\alpha_0, \alpha_1, \dots, \alpha_m$ são os parâmetros do modelo, que podem ser estimado pelo método dos quadrados mínimos.

Também é possível modelar o componente sazonal de uma série temporal por meio de regressão (CRYER e CHAN, 2008). Considerando uma série de frequência mensal que pode ser representada como:

$$Y_t = \beta_t + X_t \quad (17)$$

Temos que o parâmetro β_t deverá ter 12 valores diferentes, um para cada mês do ano, que poderá ser escrito como:

$$B_t = \begin{cases} \beta_1 \text{ para } t = 1, 13, 25, \dots \\ \beta_2 \text{ para } t = 2, 14, 26, \dots \\ \vdots \\ \beta_{12} \text{ para } t = 12, 24, 36, \dots \end{cases} \quad (18)$$

Um bom exemplo de aplicação de modelos de regressão para previsão é realizado por Bouzada e Saliby (2009), onde a técnica de regressão múltipla foi utilizada para a previsão de demanda de chamadas de um determinado *call center* de uma grande empresa do setor. Variáveis como o dia da semana, a ocorrência ou não de feriado e a proximidade da data com eventos especiais foram consideradas no modelo. A acurácia obtida foi 3% superior à ferramenta que estava sendo utilizada pela própria empresa.

2.5 Métodos Quantitativos simples

Desde Aristóteles, existe um senso comum entre cientistas de priorizar métodos simples em suas pesquisas (CHARLESWORTH, 1956), sendo a Navalha de Occam um exemplo disso. A preferência por simplicidade também é preferível na indústria, pois executivos e tomadores de decisões em geral tendem a não confiar em modelos que não

entendem (ZELLNER, 2001). De fato, Armstrong e Shapiro (1974) descrevem um caso onde até mesmo os analistas de previsão não sabiam explicar o modelo, desenvolvido por um fornecedor, que a empresa onde trabalhavam usava. Em um outro exemplo, aproximadamente 60 dos 90 economistas de universidades de ponta entrevistados por Soyer e Hogarth (2012) não conseguiram explicar corretamente os dados informados em outputs de modelos de regressão.

Segundo Green e Armstrong (2015), simplicidade em previsão requer que o método, a representação do conhecimento cumulativo, o relacionamento nos modelos e o relacionamento entre modelos, previsões e decisão são todos suficientemente descomplicados para os tomadores de decisão. Nesse mesmo trabalho, 97 comparações em 32 artigos científicos foram utilizadas para analisar a precisão de modelos simples contra modelos complexos. Nenhum deles fornece evidência para a ideia de que quanto maior a complexidade de um modelo, maior sua eficácia. De fato, em 25 dos artigos, a complexidade aumenta os erros de previsão em 27%.

Graefe *et al.* (2015) encontraram que a média simples de previsões criadas por diversos modelos reduz o erro de previsão em 5% quando comparados com modelos Bayesianos comumente aplicados em previsões de cenários políticos e econômicos. Schnaars (1984) usou métodos de extrapolação para produzir previsões para um intervalo de tempo de cinco anos para 98 séries anuais que representavam vendas de produtos de consumo. A acurácia da previsão ingênua (ver 2.5.2) foi tão boa quanto a dos outros cinco métodos de extrapolação usados.

2.5.1 Modelo da Média Simples

A previsão de todos os valores futuros é igual à média dos valores passados. Seja y_1, \dots, y_T a notação da série histórica temporal. Temos, então, que as previsões são determinadas pela Equação (19):

$$\hat{y}_{T+hT|T} = \bar{y} = (y_1 + \dots + y_T)/T \quad (19)$$

2.5.2 Modelo ingênuo

A previsão de todos os valores futuros é igual ao último valor observado. É utilizada como *benchmark* para outros modelos e costuma obter bons resultados para séries temporais econômicas e financeiros (HYNDMAN E ATHANASOPOULOS, 2012).

2.5.3 Modelo sazonal ingênuo

Um modelo similar ao ingênuo e útil para dados altamente sazonais é o método sazonal ingênuo. Cada valor previsto é igual ao último valor observado do mesmo período do ano. Esse método preverá, por exemplo, para os todos os próximos meses de Fevereiro, o valor observado no último mês de Fevereiro.

2.5.4 Modelo de passeio aleatório

Corresponde a uma variação do modelo ingênuo que permite que as previsões aumentem ou diminuam seu valor ao longo do tempo, onde o total de variação é igual à variação média observada na série histórica. Assim, a previsão para o tempo $T + h$ é calculada pela Equação (20).

$$y_T + \frac{h}{T-1} \sum (y_t - y_{t-1}) = y_T + h \left(\frac{y_T - y_1}{T-1} \right) \quad (20)$$

Isso é equivalente a desenhar uma reta entre o primeiro e o último valor observado e extrapolar os valores futuros.

2.6 Métricas de acurácia para seleção de modelo

Existem diversas maneiras para avaliar a qualidade do ajuste de um modelo de previsão, que representa o quão bem um modelo é capaz de reproduzir os dados que ele já incorporou (MAKRIDAKIS, WHEELWRIGHT e HYNDMAN, 1997).

Se Y_t é uma observação real de uma série temporal para o período t e \hat{Y}_t a previsão para o mesmo período, então o erro é definido como:

$$e_t = Y_t - \hat{Y}_t \quad (21)$$

A qualidade do ajuste não significa necessariamente que o modelo possui uma boa acurácia. É sempre possível obter um erro igual a zero usando um polinômio de ordem suficientemente grande. Contudo, não há garantia que esse ajuste terá uma boa previsão para valores futuros ou até mesmo para valores da série que não foram usados como *input* para o ajuste do modelo. A técnica de forçar um modelo a incorporar aleatoriedade em seu ajuste para uma dada série histórica é chamada de *overfitting*.

Esse problema pode ser resolvido medindo a acurácia da previsão fora da amostra. Isso é realizado dividindo a série em uma série de inicialização ou treino (*training set*) e uma série de teste (*test set*). Assim, a série de treino é usada para estimar os parâmetros e ajustar o modelo e a série de teste para avaliar sua acurácia. Como a série de treino não foi usada para o ajuste do modelo, as previsões obtidas são genuínas. Portanto, as métricas de erro devem ser calculadas apenas para a série de teste. (MAKRIDAKIS, WHEELWRIGHT e HYNDMAN, 1997).

As métricas de erro podem ser classificadas em:

2.6.1 Erros dependentes da escala

O erro e_t está na mesma escala que os dados Y_t . Métricas de erro que são baseadas em e_t são portanto dependentes da escala e não podem ser usadas em comparações entre séries de diferentes escalas (HYNDMAN E ATHANASOPOULOS, 2012).

As duas métricas dependentes da escala mais comuns são o erro absoluto médio (MAE) e a raiz do erro quadrático médio (RMSE), definidos como:

$$MAE = média(|e_t|) \quad (22)$$

$$RMSE = \sqrt{média(e_t^2)} \quad (23)$$

Uma variação do MAE é o erro absoluto mediano, onde a mediana dos erros é usada ao invés da média.

2.6.2 Erros percentuais

O erro percentual é dado por:

$$p_t = 100 e_t / Y_t \quad (24)$$

Métricas baseadas em erros percentuais têm a vantagem de independem da escala dos dados, sendo frequentemente usados para comparar o desempenho de previsões em diferentes séries temporais. A métrica de erro percentual mais comum é o erro percentual absoluto médio (MAPE), dado por:

$$MAPE = média(|p_i|) \quad (25)$$

Contudo, o MAPE e outras métricas baseadas no erro percentual possuem a desvantagem de serem indefinidas quando $Y_t = 0$ e ter valores extremos quando \hat{Y}_t é próximo a zero. Assim, elas não devem ser usadas para séries temporais intermitentes.

2.7 Intervalos de predição

De acordo com Hyndman e Athanasopoulos (2012), intervalos de previsão fornecem um intervalo dentro do qual o valor de Y_t é esperado com uma certa probabilidade. Por exemplo, assumindo que os erros de previsão não são correlacionados e normalmente distribuídos, então um intervalo de previsão de 95% para a próxima observação da série é dado por:

$$\hat{Y}_t = 1,96\sigma \quad (26)$$

onde σ é uma estimativa do desvio padrão da distribuição da previsão.

Uma característica dos intervalos de previsão é que eles aumentam em tamanho a medida em que o intervalo de previsão aumenta devido a incerteza associada com a previsão aumentar.

2.8 Estratégia de criação de modelo de previsão

De acordo com Makridakis, Wheelwright e Hyndman (1997), existem cinco etapas básicas de um projeto de previsão quantitativa:

1. **Definição do problema:** algumas vezes é a tarefa mais difícil do analista de previsões. Envolve o desenvolvimento de um profundo entendimento de como as previsões serão usadas, quem é o público-alvo e como as previsões se enquadram na organização. Previsões mais detalhadas levam em consideração aspectos além das séries históricas, como quais produtos estão em estoque, quem os usa, qual o tempo de produção deles e assim em diante.
2. **Coletar informações**, sendo elas de dois tipos: dados estatísticos e o a *expertise* de pessoas chave do negócio.
3. **Análise exploratória preliminar:** antes de modelar os dados, é necessário conhecê-los melhor. Por isso, o analista deve calcular estatísticas básicas como média, desvio padrão e valores mínimo e máximo associados com cada conjunto de dados. Quando há mais de uma série temporal a ser analisada, podem ser usadas técnicas de correlação e correlação cruzada. Uma ferramenta comumente usada em séries temporais é a decomposição dos dados para verificar componentes como tendência, sazonalidade e ciclos, além de identificar anomalias.
4. **Escolha e ajuste de um modelo:** envolve a aplicação dos dados como inputs de modelos quantitativos. Cada modelo envolve uma série de suposições que devem ser averiguadas nos dados para que a previsão faça sentido.
5. **Usar e avaliar um modelo de previsão:** uma vez que um modelo foi escolhido e seus parâmetros estimados apropriadamente, ele deve ser usado para realizar previsões, sendo monitorado regularmente pelos seus usuários pelas várias métricas de erros de previsão existentes na literatura.

3. PROCEDIMENTOS METODOLÓGICOS

O procedimento metodológico seguiu o modelo das cinco etapas proposto por Makridakis, Wheelwright e Hyndman (1997): definição do problema, coleta de dados, análise exploratória preliminar, ajuste de modelos e escolha do modelo.

A empresa tem mais de cem centros de distribuição (CD) espalhados por todo o Brasil. Cada um deles armazena e vende centenas de produtos diferentes. Consequentemente, todos os meses são realizadas mais de 12 mil previsões de vendas. Portanto, a ferramenta de previsão de demanda utilizada pela empresa não só necessita fornecer previsões precisas mas também ser automatizada.

O método do presente trabalho foi dividido nas seguintes etapas

1. Coleta de dados: Foram coletadas as séries históricas de vendas dos produtos negociados por 23 centros de distribuição da empresa localizados na região Nordeste do Brasil entre Janeiro de 2015 a Agosto de 2016. As fontes dos dados são sistemas internos da companhia. Devido às questões de confidencialidade e segredo industrial, tais dados não poderão ser disponibilizados ao público e algumas informações (como os verdadeiros nomes e a localidade exata dos centros de distribuição) não serão reveladas no presente trabalho.
2. Análise exploratória preliminar: A funcionalidade do sistema proposto foi preliminarmente testada com a série temporal das vendas do produto mais vendido pelo centro de distribuição de maior volume de vendas dentre os 23 analisados.
3. Automação do processo: Após a realização bem-sucedida do teste, foi escrito um pacote na linguagem R para automatizar o processo de ajuste de diferentes modelos e seleção daquele com o menor erro. O pacote foi disponibilizado gratuitamente na Internet¹ e pode ser utilizado para previsões das mais diversas naturezas. O código criado está disponível no Apêndice A.

Decidiu-se usar a linguagem R para o desenvolvimento do sistema proposto devido à grande quantidade de modelos de previsão disponíveis no pacote *forecast*, desenvolvido por

¹ <https://cran.r-project.org/web/packages/mafs/index.html>

Hyndman e Khandakar (2008). A partir dessa facilidade, algoritmos estatísticos complexos podem ser usados em poucas linhas de código, recurso que não está presente em outros programas computacionais semelhantes.

4. DESCRIÇÃO DO SISTEMA PROPOSTO

O ajuste de modelos é a etapa de maior complexidade do trabalho. O passo-a-passo do método será descrito a seguir.

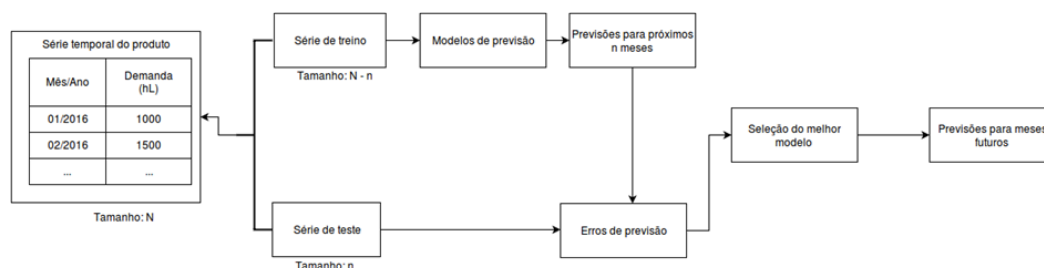
A função principal do método é chamada *select_forecast()* e tem como inputs do usuário uma série temporal, o tamanho da série de teste (*test_size*), o tamanho do horizonte de previsão (*horizon*) e a métrica de erro escolhida para a comparação entre modelos. Para este trabalho, foi escolhida a métrica “MAE” (desvio absoluto médio) devido ao fato de algumas das séries de demandas analisadas serem intermitentes, o que implicaria a inviabilidade de se utilizar o MAPE, visto que não se pode utilizar o número 0 como denominador.

Inicialmente, a série temporal é dividida em uma série de treino (*training*) e uma série de teste (*test*). O tamanho da série de teste é escolhida pelo usuário. Para este trabalho, devido ao tamanho limitado de menos de dois anos de dados fornecidos, decidiu-se por criar séries de treino de três meses de comprimento.

A série de treino é então aplicada em 18 modelos de previsão para obter previsões para os meses da série de teste. Tais modelos estão disponíveis no pacote da linguagem R chamado *forecast* (Hyndman e Khandakar, 2008). Os modelos de previsão disponíveis são apresentados no Quadro 2.

A partir dos ajustes criados, são geradas previsões para os três meses seguintes ao último mês da série de treino. As previsões são então comparadas com os valores reais da série de treino por meio da métrica de erro escolhida. O modelo cuja previsão obteve a melhor acurácia é então aplicada à série temporal original, obtendo, assim, valores de demanda para os meses futuros, além do intervalo de predição. Este processo é ilustrado pela Figura 4.

Figura 4 - Ilustração do funcionamento do algoritmo de seleção de modelo de previsão.



Fonte: Autoria própria.

Quadro 2 - Modelos de previsão utilizados no trabalho

Nome do modelo	Descrição	Nome da função no pacote forecast .
auto.arima	Modelo ARIMA	auto.arima()
ets	Suavização exponencial por modelo de estado espaço	ets()
nnetar	Redes neurais artificiais	nnetar()
tbats	Modelo TBATS	tbats()
bats	Modelo BATS	bats()
stlm_ets	Suavização exponencial por modelo de estado espaço com ajuste sazonal pelo método STL	stlm()
stlm_arima	Modelo ARIMA com ajuste sazonal pelo método STL	stlm()
StructTS	Modelo estrutural	StructTS()
meanf	Média simples	meanf()
naive	Modelo ingênuo	naive()
snaive	Modelo ingênuo sazonal	snaive()
rwf	Passeio aleatório	rwf()
rwf_drift	Passeio aleatório com deriva	rwf()
splinef	Suavização por <i>splines</i> cúbicas	splinef()
thetaf	Método Theta	thetaf()
croston	Modelo de Croston	croston()
tslm	Regressão linear	tslm()
hybrid	Modelo híbrido	hybrid()


Fonte: Autoria própria.

5. RESULTADOS DA SIMULAÇÃO

5.1 Análise exploratória

A Figura 5 mostra a série histórica agregada do volume de vendas dos CDs da região Nordeste da empresa.

Figura 5 – Série histórica do volume de vendas da região Nordeste

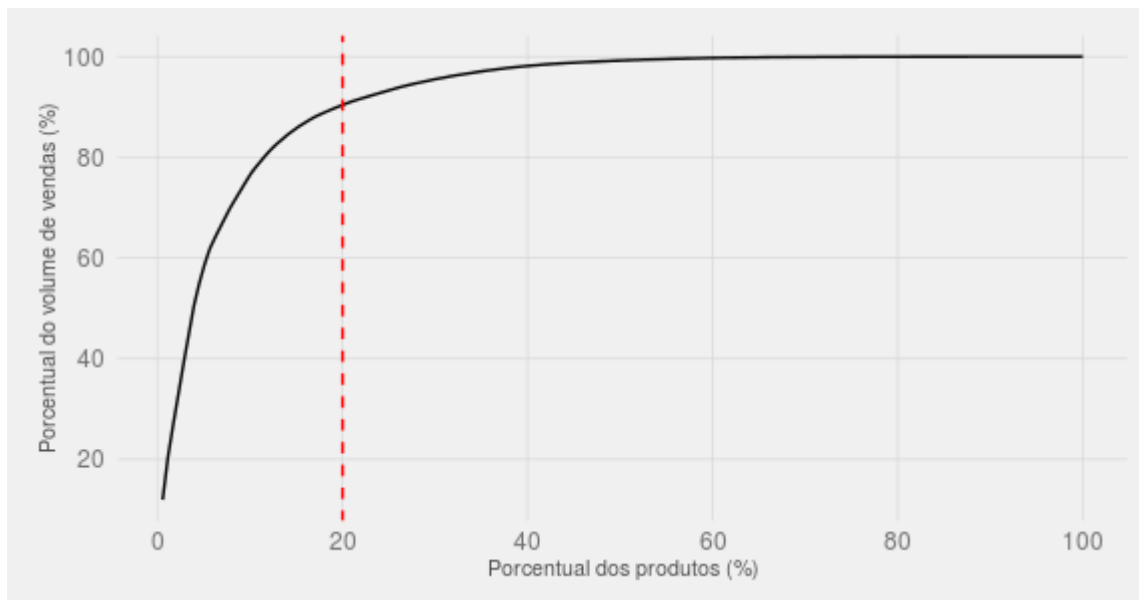


Fonte: Autoria própria

Como mostra a Figura 5, o desempenho mensal das vendas é irregular. Existem alguns períodos onde visualmente há um componente de tendência. Além disso, não é possível observar o componente de sazonalidade na série, muito em parte por conta de o período analisado ser menor que 2 anos. O volume mensal médio de vendas é de 1,081 milhões de hectolitros.

Os 175 produtos vendidos na região apresentam demandas de diferentes magnitudes. A Figura 6 mostra a curva ABC dos produtos.

Figura 6 – Curva ABC dos produtos vendidos na região Nordeste



Fonte: Autoria própria.


A Figura 6 mostra que 35 ou 20% dos 175 produtos correspondem a 80% do volume de vendas. Seria natural concentrar os esforços nesses produtos mais importantes e testar a validade do sistema proposto no presente trabalho apenas para eles. Contudo, decidiu-se incluir nos testes todos os produtos, independentemente da demanda.

5.2 Exemplo de aplicação do sistema

Durante o desenvolvimento do trabalho, foram realizadas 7.767 previsões mensais de diferentes produtos em diferentes centros de distribuição. Como seria impraticável comentar cada um desses casos, será mostrado o funcionamento do método para a série histórica do produto mais popular (chamado de P001 por motivos de confidencialidade) vendido pelo maior centro de distribuição no Nordeste (chamado de C01).

A série temporal histórica das vendas do produto P001 pelo centro de distribuição C01 é mostrada na Figura 7.

Figura 7 – Série histórica do produto de maior demanda



Fonte: Autoria própria.

Percebe-se pela Figura 7 que, apesar de esse ser o produto de maior demanda do centro de distribuição C01, sua série temporal apresenta uma tendência de queda a partir de Fevereiro de 2015. Portanto, espera-se que as previsões obtidas prossigam com essa tendência.

Dos modelos de previsão incluídos no sistema proposto, apenas os baseados na decomposição sazonal pelo método STL não foram usados por eles precisarem de um período de tempo de no mínimo dois anos. Portanto, a precisão do sistema proposto poderia ser ainda melhor caso um período maior de dados fosse disponibilizados.

Os dados de Janeiro de 2015 a Maio de 2016 foram usados para obter as previsões para Junho, Julho e Agosto por cada um dos modelos disponíveis, que foram então comparadas com os dados reais para esse trimestre.

O resultado dos ajustes obtidos em cada modelo é mostrado nas figuras presentes no Apêndice B.

Os resultados dos ajustes obtidos são apresentados na Tabela 1.

Tabela 1 – Erros obtidos pelos métodos de previsão.

Modelo	RMSE	MAE	MAPE
rwf_drift	4180,654	3963,575	16,03998
splinef	4399,647	4342,502	17,40861
naive	4834,035	4647,575	18,75864
rwf	4834,035	4647,575	18,75864
ets	5422,768	5257,23	21,18182
StructTS	5456,741	5329,792	21,35556
tslm	6210,356	6063,455	24,33111
nnetar	6236,485	6129,297	24,60648
bats	6726,572	6581,88	26,40727
thetaf	7113,854	7012,895	28,13093
meanf	10195,56	10108,49	40,46391
auto.arima	10195,56	10108,49	40,46391
croston	10284,02	10197,71	40,81852
hybrid	10369,9	10284,3	41,16272
tbats	10718,98	10636,19	42,56136
snaive	11443,78	11364,73	45,40185

Fonte: Autoria própria.

De acordo com a Tabela 1, o modelo do passeio aleatório com deriva (rwf_drift) teve o melhor desempenho, apresentando um MAPE de 16% e um MAE de 3963,575 hectolitros. Nota-se, também, que apesar de o sistema proposto conter 18 modelos de previsão, apenas 16 foram usados. Isso ocorreu porque os modelos baseados na decomposição pelo modelo estrutural de Harvey exigem pelo menos 24 meses para as séries temporais, o que é maior que as séries analisadas neste trabalho.

Assim, os resultados desse modelo foram comparados com as previsões de três fontes diferentes da empresa: duas são fornecidas pelo sistema oficial de previsão de demanda, chamadas N1 e N2, e a outra é obtida por meio de uma análise qualitativa das previsões obtidas pelo sistema, considerando fatores (regressores externos) como ações de preços promocionais, momento econômico do Brasil, preço do dólar, etc, chamada de crítica. Tal comparação é mostrada na Tabela 2.

Tabela 2 – Comparação do erro de previsão para o produto P001

Mês	Real (hL)	Crítica		N1		N2		rwf_drift	
		Vol. Previsto (hL)	Erro (%)	Vol. Previsto (hL)	Erro (%)	Vol. Previsto (hL)	Erro (%)	Vol. Previsto (hL)	Erro (%)
Jun	26568,15	35764,11	34,61	34219,74	28,80	35431,69	33,36	29194,95	9,89
Jul	25708,28	30722,40	19,50	34147,84	32,83	31793,98	23,67	29194,95	13,56
Ago	23417,70	27497,34	17,42	31057,33	32,62	29894,51	27,66	29194,95	24,67
Media			23,85		31,42		28,23		16,04

Fonte: Autoria própria.

Conforme mostra a Tabela 2, o método rwf_drift apresentou um erro médio de 16,04%, o que é 7,81% menor que o erro da crítica feita pelos profissionais de previsão de vendas da empresa. Além disso, em dois dos três meses avaliados, o método rwf_drift obteve a melhor precisão. Portanto, o sistema proposto no presente trabalho, na comparação realizada aqui, apresentou um melhor desempenho que as previsões usadas na empresa.

5.3 Resultados do sistema proposto

Após mostrar na seção 5.2 um exemplo bem-sucedido de aplicação do sistema, os resultados de sua aplicação em todas as séries temporais disponíveis foram comparados com a acurácia obtida pelas previsões realizadas pela empresa no geral ou estratificados por produto, centro de distribuição e mês.

5.3.1 Resultados gerais

Semelhantemente aos dados da Tabela 2, foram geradas 7.767 previsões para os meses de Junho, Julho e Agosto de 175 produtos em 23 centros de distribuição. O erro absoluto e o relativo médio obtido por cada fonte de previsão são mostrados na Tabela 3. Ressalta-se que, para o cálculo do erro absoluto, foram desconsideradas as previsões onde o volume real de vendas foi 0, o que inviabiliza o cálculo visto que não se pode dividir um número por 0.

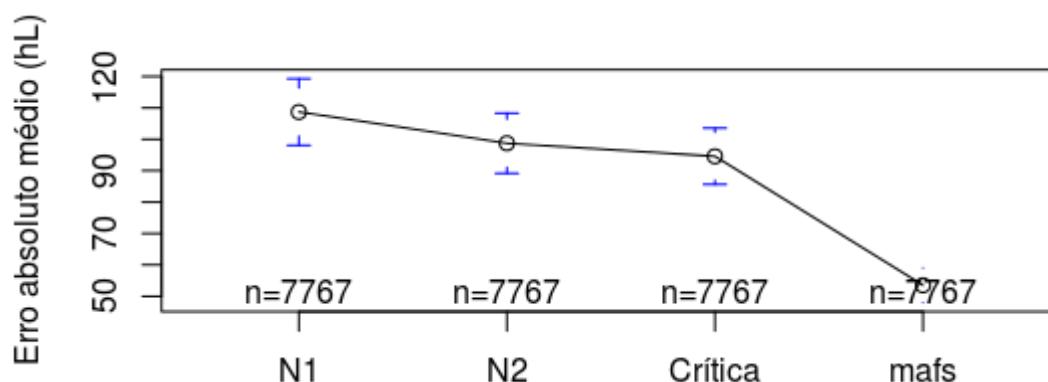
Tabela 3 – Resultados gerais do sistema proposto comparados com os métodos da empresa

Método	Erro absoluto médio (hL)	Erro relativo médio (%)
N1	108,70	238,50
N2	98,74	215,51
Crítica	94,58	196,12
mafs	53,51	55,11

Fonte: Autoria própria.

Como mostra a Tabela 3, o sistema proposto obteve a melhor acurácia tanto em termos absolutos quanto em relativos. A Figura 8 mostra a diferença entre as médias e o intervalo de confiança dos quatro métodos.

Figura 8 – Erro absoluto médio e intervalo de confiança dos métodos de previsão avaliados



Fonte: Autoria própria.

Nota-se pela Figura 8 que, além do sistema proposto ter o menor erro absoluto médio, há pouca diferença entre os resultados dos métodos de previsão da empresa. Para avaliar se tais diferenças são estatisticamente significantes, aplicou-se o teste da Análise de variância (ANOVA) para avaliar duas hipóteses:

- **Hipótese nula (H_0):** Os quatro métodos apresentam os mesmos resultados e as diferenças entre eles se devem a aleatoriedade;
- **Hipótese alternativa (H_A):** Existe uma diferença significativa do erro absoluto médio dos quatro métodos avaliados.

Ou seja, deseja-se saber se os dados coletados no experimento fornecem evidência suficiente para rejeitar a hipótese nula. Foi utilizada a função *aov()* da linguagem de programação R para a aplicação do teste ANOVA nas condições acima. Os resultados são apresentados na Tabela 4.

Tabela 4 – Resultados do teste ANOVA

Estatística do teste	Valor
Valor-F	28,78
Valor-p	2×10^{-16}

Fonte: Autoria própria.

Na Tabela 4, são apresentadas duas estatísticas resultantes do teste:

- O valor-F, que é, neste contexto, a taxa normalizada da variância entre diferentes etapas relativa à variação dentro de uma mesma etapa (Diez *et al.*, 2016). Quanto maior o valor-F, maior é a veracidade da hipótese alternativa (H_A).
- O valor-p, que é a probabilidade de observar dados no mínimo tão favoráveis à hipótese alternativa quanto os dados atuais, partindo do pressuposto que a hipótese nula é verdadeira. Na pesquisa científica, costuma usar o nível de significância (valor) de 0,05 (Diez *et al.*, 2016). Isto é, se o valor-p é menor que 0,05, então há evidências suficientes para rejeitar a hipótese nula.

Como a estatística F é muito superior a 1 e a estatística p é muito menor que 0,05, conforme mostrado na Tabela 4, pode-se aceitar H_A e concluir que as diferenças de acurácia dos métodos é estatisticamente significativa.

Entretanto, o teste ANOVA informa apenas que nem todas os métodos são iguais. Como foram analisadas quatro métodos de previsão de vendas diferentes, é possível que apenas um deles não seja igual às outras. Por isso, após o teste ANOVA, é necessário usar testes *post hoc* para identificar quais pares de métodos diferem significativamente entre si².

Assim, foi aplicado o teste de significância honesta de Tukey (teste de Tukey ou teste HSD), que é aplicado quando o teste F for significativo³, para testar toda e qualquer diferença entre as médias de erro absoluto. Mais detalhes sobre esse teste estatístico podem ser

² http://www.ufpa.br/metodologiza/decisao_testes.html

³ <http://www.de.ufpb.br/~tarciana/MPIE/Aula19.pdf>

encontrados em Tukey (1949). Foi usada a função *TukeyHSD()*, presente na linguagem de programação R. Tais resultados são apresentados na Tabela 5.

Tabela 5 – Resultados do teste de Tukey

Comparação	Diferença média (hL)	Valor-p
N2-N1	-9,957082	0,4054134
Crítica-N1	-14,115068	0,1225085
Crítica-N2	-4,157986	0,9160069
mafs-N1	-55,184742	0,0000000
mafs-N2	-45,227661	0,0000000
mafs-Crítica	-41,069674	0,0000000

Fonte: Autoria própria.

Os dados da Tabela 5 confirmam que o sistema proposto é significativamente diferente dos métodos da empresa que, por sua vez, não apresentam diferenças significativas entre si.

5.3.2 Resultados agregados por produto.

Para calcular os resultados agregados por produto, foram obtidos os volumes reais e previstos de cada um dos 175 produtos acumulados para os três meses da série de teste (Junho, Julho e Agosto). Um exemplo da tabela resultante para o produto P001 é mostrado na Tabela 6.

Tabela 6 – Resultados agregados para o produto P001

Produto	Volume real (hL)	Método de previsão	Vol. previsto (hL)	Erro absoluto (hL)	Erro relativo (%)	Ranking de acurácia
P001	294033,2	N1	330254,5	36221,3	12,3	4
		N2	322616,4	28593,2	9,7	3
		Crítica	317795,0	23761,8	8,1	2
		mafs	305777,6	11744,4	4,0	1

Fonte: Autoria própria.

Conforme mostra a Tabela 6, o volume acumulado do produto P001 nos 23 centros de distribuição nos três meses da série de teste foi 294033,2hL. A melhor acurácia observada foi a do sistema proposto, com um erro relativo de 4,0%, seguida pela Crítica, pelo N2 e pelo N1.

Para determinar o melhor método para os resultados agregados por produto, foi criado um sistema de pontuação em que o sistema de menor erro absoluto ganhava 5 pontos, o de 2º menor erro 3 pontos, o de 3º menor 1 ponto e o de maior erro nenhum ponto. Os resultados

desse sistema de pontuação são apresentados na Tabela 7.

Tabela 7 – Pontuação agregada por produto dos métodos de previsão

Método	Número de previsões				Pontuação total
	Menor erro	2º menor erro	3º menor erro	4º menor erro	
N1	49	29	35	62	367
N2	19	63	63	30	347
Crítica	19	52	58	46	309
mafs	88	31	19	37	552

Fonte: Autoria própria.

De acordo com a Tabela 7, o sistema proposto obteve um desempenho muito superior aos métodos da empresa, obtendo a melhor previsão para 50,3% dos produtos. No sistema de pontuação criado, o método teve 552 pontos, 185 a mais que o método de segundo melhor desempenho, o N1.

Outra forma de analisar os resultados é pela média do erro absoluto de cada sistema para todos os produtos. Adicionalmente, foi calculado a mediana do erro absoluto dos métodos para mostrar o efeito das anomalias nos resultados. Tais resultados são apresentados na Tabela 8.

Tabela 8 – Erro absoluto agregado por produto dos métodos de previsão

Método	Erro absoluto médio (hL)	Erro absoluto mediano (hL)
N1	2072,1	132,9
N2	1505,5	118,0
Crítica	1338,5	162,8
mafs	691,8	50,8

Fonte: Autoria própria

De acordo com a Tabela 8, novamente, o sistema proposto obteve o melhor desempenho, tanto pela média quanto pela mediana.

5.3.3 Resultados agregados por centro de distribuição

Para calcular os resultados agregados por produto, foram obtidos os volumes reais e previstos de cada um dos 23 centros de distribuição para os três meses da série de teste (Junho, Julho e Agosto). Um exemplo da tabela resultante para o centro de distribuição C01 é mostrado na Tabela 9.

Tabela 9 – Resultados agregados para o centro de distribuição C01.

Centro de distribuição	Volume real (hL)	Método de previsão	Vol. previsto (hL)	Erro absoluto (hL)	Erro relativo (%)	Ranking de acurácia
C01	467502,1	N1	485761,1	18259,1	3,9	2
		N2	510258,6	42756,6	9,1	4
		Crítica	506384,1	38882,1	8,3	3
		mafs	479125,5	11623,4	2,5	1

Fonte: Autoria própria.

Conforme mostra a Tabela 9, o volume acumulado do centro de distribuição C01 nos três meses da série de teste foi 467502,1hL. A melhor acurácia observada foi a do sistema proposto, com um erro relativo de 2,5%.

Para determinar o melhor método de previsão para os resultados agregados por centro de distribuição, foi utilizado o mesmo sistema de pontuação descrito na seção anterior. Os resultados desse sistema de pontuação agregados por centro de distribuição são apresentados na Tabela 10.

Tabela 10 – Pontuação agregada por centro de distribuição dos métodos de previsão

Método	Número de previsões				Pontuação total
	Menor erro	2º menor erro	3º menor erro	4º menor erro	
N1	2	8	7	6	41
N2	6	5	4	8	49
Crítica	1	6	8	8	31
mafs	14	4	4	1	86

Fonte: Autoria própria.

De acordo com a Tabela 10, semelhantemente aos resultados agregados por produto, o sistema proposto obteve um desempenho muito superior aos métodos da empresa, obtendo a melhor previsão para 60,9% dos produtos. No sistema de pontuação criado, o método teve 86 pontos, 37 a mais que o método de segundo melhor desempenho, o N2.

O erro absoluto médio agregado por centro de distribuição dos quatro métodos de previsão de demanda é mostrado na Tabela 11.

Tabela 11 - Erro absoluto agregado por centro de distribuição dos métodos de previsão

Método	Erro absoluto médio (hL)	Erro absoluto mediano (hL)
N1	6910,5	4368,7
N2	9128,3	3717,1
Crítica	9405,2	4663,4
mafs	2796,9	1718,3

Fonte: Autoria própria

De acordo com a Tabela 11, novamente, o sistema proposto obteve o melhor desempenho, tanto pela média quanto pela mediana.

5.3.4 Resultados totais agregados por mês

Finalmente, foram analisados os resultados agregados de Junho, Julho e Agosto dentre todos os centros de distribuição. Os resultados são mostrados na Tabela 12.

Tabela 12 - Erro absoluto agregado por mês dos métodos de previsão

Mês	Volume real (hL)	Método de previsão	Vol. previsto (hL)	Erro absoluto (hL)	Erro relativo (%)
Junho	1017189,0	N1	919482,8	97706,2	9,6
		N2	966889,0	50299,9	4,9
		Crítica	1031088,7	13899,7	1,4
		mafs	964041,7	53147,3	5,2
Julho	883600,0	N1	898535,0	14935,0	1,7
		N2	955158,3	71558,3	8,1
		Crítica	963612,9	80013,0	9,1
		mafs	911593,8	27993,8	3,1
Agosto	890383,2	N1	975353,0	84969,8	9,5
		N2	973076,1	82693,0	9,3
		Crítica	945840,0	55456,8	6,2
		mafs	890383,2	23708,7	2,7

Fonte: Autoria própria.

Conforme mostra a Tabela 12, o sistema proposto obteve a terceira melhor acurácia para o mês de Junho, a segunda melhor para Julho e a melhor para Agosto. Além disso, o método mafs apresentou o menor erro relativo máximo, de 5,2%, comparado com os métodos N1 (9,6%), N2 (8,1%) e Crítica (6,2%). O erro relativo médio do sistema proposto também foi o menor (3,7%).

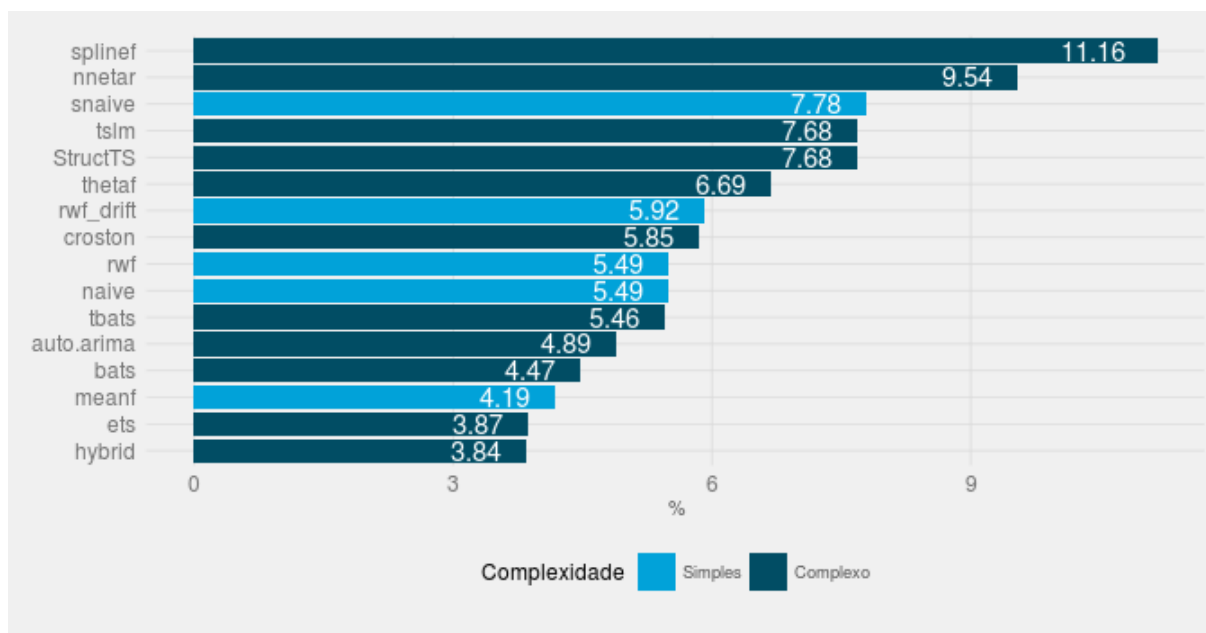
Contudo, deve-se ressaltar que os resultados apresentados no presente capítulo foram obtidos com um curto período de tempo usado para a modelagem das séries temporais (menos de 24 meses), além de séries de testes de apenas três meses. Como sugestão para trabalhos futuros, recomenda-se o teste do sistema proposto para séries temporais mais longas.

Além disso, no período analisado, a tendência geral do comércio de bebidas foi de queda devido ao momento econômico do Brasil. Isto é, o sistema não foi testado para um período longo o suficiente em que os dados apresentam variações sistemáticas não só de queda mas também de aumento de vendas.

5.4 Resultados dos modelos usados no sistema

Decidiu-se analisar a eficácia dos dezoito modelos de previsão utilizados no sistema proposto. O percentual de vezes em que os modelos obtiveram o menor MAE para cada previsão são apresentados na Figura 9.

Figura 9 – Resultados dos modelos de previsão usados no sistema



Fonte: Autoria própria

De acordo com a Figura 9, o modelo de *splines* cúbicas suavizadas obteve o melhor desempenho em 11,16% das previsões realizadas. Os modelos categorizados como complexos, de acordo com a classificação de Hyndman (SITE FPP), obtiveram um resultado superior aos modelos simples. Apesar disso, nota-se que alguns dos modelos clássicos amplamente utilizados entre analistas de previsão, como o de suavização exponencial e o modelo ARIMA, obtiveram um desempenho inferior ao de modelos simples como o ingênuo (*naive*).

6 CONCLUSÃO

A previsão de demanda é um processo chave para o planejamento estratégico e para o processo produtivo das empresas. Além disso, empresas de porte médio ou grande, que contam com centenas ou milhares de produtos em seu portfólio, necessitam realizar previsões de vendas nessa mesma proporção. Portanto, há a necessidade de soluções de previsões que sejam eficientes em termos de acurácia e automatizadas, com pouca necessidade de intervenção humana.

No presente trabalho, o sistema proposto, que seleciona um método de previsão de demanda dentre os 18 escolhidos, foi testado para séries temporais de vendas de mais de 100 produtos de 23 centros de distribuição na região Nordeste de uma empresa distribuidora de bebidas. Os resultados obtidos com essa simulação foram comparados com os dos métodos usados pela empresa, cujas previsões são realizadas por um sistema computacional e ajustadas por especialistas de acordo com informações sobre ações promocionais e indicadores macroeconômicos.

Os resultados gerais do sistema proposto foram melhores que os métodos da empresa. Considerando todas as mais de 7000 previsões realizadas, o erro relativo médio do sistema proposto foi de 55,11%, contra 196,12% da previsão realizada por especialistas da empresa. Na análise dos resultados agregados por produto e por centro de distribuição, o sistema proposto também apresentou os melhores resultados de acurácia. Finalmente, na análise de resultados agregados por mês para o trimestre Junho, Julho e Agosto, o sistema do presente trabalho obteve o menor erro relativo médio.

Contudo, deve-se ressaltar que o período das séries temporais analisadas na simulação de resultados é curto. De fato, é inferior a 24 meses, o que é insuficiente para que os dados apresentem claros comportamentos sazonais. Trabalhos futuros a partir deste trabalho poderiam ser realizados utilizando séries temporais maiores, de pelo menos 60 meses.

Outra limitação dos resultados apresentados é que, como consequência do exposto no parágrafo anterior e do contexto macroeconômico do Brasil no período analisado, não pode-se afirmar que sistema foi testado para um período longo o suficiente em que os dados apresentam variações sistemáticas não só de queda mas também de aumento de vendas.

REFERÊNCIAS BIBLIOGRÁFICAS

ANDRIOLO, M. V. Análise de métodos não lineares para previsão de vazões médias mensais. 2006. Dissertação (Mestrado em Engenharia de Recursos Hídricos e Ambiental) – Universidade Federal do Paraná, Curitiba, 2006.

ARMSTRONG, J.S.; SHAPIRO, A.C. (1974). Analyzing quantitative models. *Journal of Marketing*, v. 38, p. 61–66, 1974.

ASSIMAKOPOULOS, V.; NIKOLOPOULOS, K. (2000). The theta model: a decomposition approach to forecasting. *International Journal of Forecasting*, v. 16, p. 521-530, 2000.

BOUZADA, M. A. C.; SALIBY, E. (2009). Prevendo a demanda de ligações em um call center por meio de um modelo de Regressão Múltipla. *Gestão & Produção*, v. 16, n.3, p. 382-397, 2009.

BRANCO, S. T.; SAMPAIO, R. J. B. Aplicação de redes neurais artificiais em modelos de previsão da demanda para equipamentos de infraestrutura de telecomunicações. In: XXVII ENCONTRO NACIONAL DE ENGENHARIA DE PRODUÇÃO. Rio de Janeiro, 2008.

BROCKWELL, P. J.; DAVIS, R. A. *Introduction to Time Series and Forecasting*. New York: Springer, 1996.

BROWN, R.G. (1959). *Statistical Forecasting for Inventory Control*. New York: McGraw-Hill, 1959.

CALOBA, G. M.; CALOBA, L. P.; SALIBY, E. (2002). Cooperação entre redes neurais artificiais e técnicas 'clássicas' para previsão de demanda de uma série de vendas de cerveja na Austrália. *Pesqui. Oper.* [online]. 2002, vol.22, n.3, pp.345-358.

CHARLESWORTH, M.J. (1956). Aristotle's razor. *Philosophical Studies*, v. 6, p. 105–112, 1956.

CLAVERIA, O.; TORRA, S. (2014). Forecasting tourism demand to Catalonia: neural networks vs. time series models. *Economic Modelling*, v. 36, p. 220-228, 2014.

CLEVELAND, R. B.; CLEVELAND, W. S.; McRAE, J.E.; TERPENNING, I. (1990). STL: A Seasonal-Trend Decomposition Procedure Based on Loess. *Journal of Official Statistics*, v.6, p.3–73, 1990.

COWPERTWAIT, P.S.P.; METCALFE, A.V. *Introductory Time Series with R*. New York: Springer, 2009.

CROSTON, J. D. (1972). Forecasting and stock control for intermittent demands. *Operational*

Research Quarterly, v. 23, p.289–303, 2972.

CRYER, J. D.; CHAN, K. S. Time Series Analysis with Applications in R. New York: Springer, 2008.

CUI, W.; GUO, D. Vehicle delay series forecast based on trajectories of GPS tracked cabs. In: 23rd International Conference on Geoinformatics, 2015.

DIEBOLD, F.X. (2015). Forecasting in Economics, Business, Finance and Beyond. Department of Economics, University of Pennsylvania, <http://www.ssc.upenn.edu/~fdiebold/Textbooks.html>.

DOMINGUES, J. S.; GONÇALVES, M. C.; BRAZ, S. C.; PEREIRA, F. J. Usando *splines* cúbicas na modelagem matemática da evolução populacional de Pirapora/MG. ForScience, v. 2(1):17-30, 2014a.

GARDNER, E. S. (1985). Exponential Smoothing: The state of the art. Journal of Forecasting, v. 4, p. 1-28, 1985.

GRAEFE, A.; KÜCHENHOFF, H.; STIERLE, V.; RIEDL, B. (2015). Limitations of ensemble Bayesian model averaging for forecasting social science problems. International Journal of Forecasting, v. 31, p. 943-951, 2015.

GREEN, K. C.; ARMSTRONG, J. S. (2015). Simple versus complex forecasting: the evidence. Journal of Business Research, v. 68, p. 1678-1685, 2015.

HARVEY, A. C.; PETERS, S. (1990). Estimation Procedures for Structural Time Series Models. Journal of Forecasting, v. 9, p. 89-108, 1990.

HOLT, C.C. (1957). Forecasting seasonals and trends by exponentially weighted moving averages. ONR Memorandum (Vol. 52), Pittsburgh, PA: Carnegie Institute of Technology.

HYNDMAN, R. J.; KHANDAKAR, Y. (2008). Automatic time series forecasting: the forecast package. Journal of Statistical Software, v.26, p.1-22, 2008.

HYNDMAN, R. J.; KING, M. L.; PITRUN, I.; BILLAH, B. (2005). Local linear forecasts using cubic smoothing splines. Australian and New Zealand Journal of Statistics, v. 47, p. 87-99, 2005.

HYNDMAN, R. J.; KOEHLER, A. B.; SNYDER, R. D.; GROSE, S. (2002). A state space framework for automatic forecasting using exponential smoothing methods. International Journal of Forecasting, v. 18, p. 439–454, 2002.

HYNDMAN, R.J., ATHANASOPOULOS, G. (2012) Forecasting: principles and practice.

<http://otexts.org/fpp/>. Acessado em 01 de Novembro de 2016.

KAASTRA, I.; BOYD, M. (1996). Designing a neural network for forecasting financial and economic time series. *Neurocomputing*, v. 10, p. 215-236, 1996.

KOENIG, A. Previsão de demanda em séries temporais intermitentes mediante a utilização do método de Croston. 2014. Dissertação (Mestrado em Engenharia de Produção) – Universidade Federal de Santa Catarina, Florianópolis, 2014.

Lawrence, M.; GOODWIN, P.; O'CONNOR, M.; ONKAL, D. (2006). Judgmental forecasting: a review of progress over the last 25 years. *International Journal of Forecasting*, v.22, p.493-518, 2006.

LEE, C. K.; SONG, H. J.; MJELDE, J. W. (2008). The forecasting of International Expo tourism using quantitative and qualitative techniques. *Tourism Management*, v.29, p.1084-1098, 2008.

LIMA, F. J. L. Previsão de irradiação solar no nordeste do Brasil empregando o modelo WRF ajustado por redes neurais artificiais (RNAs). 2015. Tese (Doutorado em Meteorologia) – Instituto Nacional de Pesquisas Espaciais (INPE), São José dos Campos, 2015.

LIVERA, A. M.; HYNDMAN, R. J.; SNYDER, R. D. (2010). Forecasting Time Series With Complex Seasonal Patterns Using Exponential Smoothing. *Journal of the American Statistical Association* v.106, p. 1513-1527, 2010.

MAKRIDAKIS, S.; WHEELWRIGHT, S. C.; HYNDMAN, R. J. *Forecasting: Methods and Applications*. New York: Wiley, 1997.

PEREIRA, L. N. (2016). An introduction to helpful forecasting methods for hotel revenue management. *International Journal of Hospitality Management*, v. 58, p. 13-23, 2016.

R Core Team (2016). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria. Disponível em <<https://www.R-project.org/>>. Acesso em 30 de nov. de 2016.

ROSSUM, G. van. Python tutorial, Technical Report CS-R9526, Centrum voor Wiskunde en Informatica (CWI), Amsterdam, 1995.

ROUDIER, P.; DUCHARNE, A.; FEYEN, L. Climate change impacts on runoff in West Africa: a review. *Hydrol. Earth Syst. Sci.*, 18, 2789–2801, 2014.

SCHNAARS, S.P. (1984). Situational factors affecting forecast accuracy. *Journal of Marketing Research*, v. 21, p. 290–297, 1984.

- SILVA, M. A. V. da; D'AGOSTO, M. de A. Modelo de previsão de oferta e demanda de bioetanol hidratado para apoio ao planejamento estratégico de transportes no Brasil. J. Transp. Lit., Manaus, v. 7, n. 3, p. 214-239, 2013.
- SOYER, E.; HOGARTH, R. (2012). Illusion of predictability: How regressions statistics mislead experts. International Journal of Forecasting, v. 28, v. 695–711, 2012.
- TAYLOR, J. W. (2003). Short-term electricity demand forecasting using double seasonal exponential smoothing. Journal of Operational Research Society, v. 54, p. 799-805.
- THEODOSIOU, M. (2011). Forecasting monthly and quarterly time series using STL decomposition. International Journal of Forecasting, v. 27, p.1178-1195, 2011.
- WHEELWRIGHT, S.; MAKRIDAKIS, S. Forecasting Methods for Management. New York: Wiley, 1985.
- WINTERS, P.R. (1960). Forecasting sales by exponentially weighted moving averages. Management Science, v. 6, p. 324-342, 1960.
- ZELLNER, A. (2001). Keep it sophisticatedly simple. Cambridge: Cambridge University Press, 2001.

APÊNDICE A – CÓDIGO DO SISTEMA CRIADO

```

apply_selected_model <- function(x, model_name, horizon) {

  available_models <- available_models()

  if (!(model_name %in% available_models)) stop("Your model is not available. Please run
avaiaableModels() to see the list of available models")
  # former aplicarMelhorModelo()
  switch(model_name,
    "auto.arima" = auto.arima(x, ic='aicc', stepwise=FALSE), # 1
    "ets" = ets(x, ic='aicc', restrict=FALSE, opt.crit = "mae"), #2
    "nnetar" = nnetar(x, p=12, size=12, repeats = 24), # 3
    "tbats" = tbats(x, ic='aicc', seasonal.periods=12), # 4
    "bats" = bats(x, ic='aicc', seasonal.periods=12), # 5
    "stlm_ets" = stlm(x, s.window=12, ic='aicc', robust=TRUE, method='ets'), # 6
    "stlm_arima" = stlm(x, s.window=12, ic='aicc', robust=TRUE, method='arima'), # 7
    "StructTS" = StructTS(x), #8
    "meanf" = meanf(x, h = horizon), #9
    "naive" = naive(x, h = horizon), #10
    "snaive" = snaive(x, h = horizon), #11
    "rwf" = rwf(x, h = horizon), #12
    "rwf_drift" = rwf(x, drift = TRUE, h = horizon), #13 ### NOVO
    "splinef" = splinef(x, h = horizon), #14
    "thetaf" = thetaf(x, h = horizon), #15
    "croston" = croston(x, h = horizon), #16
    "tslm" = tslm(x ~ trend + season), #17
    "hybrid" = forecastHybrid::hybridModel(x) #18
  )
}

apply_all_models <- function(x, horizon) {
  # former aplicarTodosModelos

  mods <- available_models()
  models <- list() # initiates empty list to be filled by forecast models

  for (i in 1:length(mods)) {
    mod <- mods[i]
    fit <- try(apply_selected_model(x, mod, horizon), silent = TRUE)
    if (!inherits(fit, "try-error")) models[[i]] <- fit
  }
  return(models)
}

select_forecast <- function(x, test_size, horizon, error) {
  # Checks if defined error metric is available
  error_metrics <- error_metrics()
  if (!(error %in% error_metrics)) stop("Your error metric is not available. Please run error_metrics() to
see the list of available metrics.")

  x_split <- CombMSC::splitTrainTest(x, length(x) - test_size)

```

```

training <- x_split$train
test <- x_split$test
models_list <- apply_all_models(training, horizon = test_size)

available_models <- available_models()
num <- length(available_models)

# Apply forecast() function to created models
# some error handling:
# for each element in model_list, if the model was not created (model_list[i] == NULL),
# it replaces the element with a too big numeric vector of the same
# characteristics as the test set.
# This procedure, of course, needs to be improved, but it does the work for now.
forecasts <- lapply(models_list, function(i) tryCatch({forecast(i, h = test_size)},
                                                    error = function(e) {
                                                        x <- rep(1e9, test_size)
                                                        x <- ts(x, start = start(test) - test_size/12,
                                                            frequency = frequency(test))
                                                        x <- naive(x)
                                                        x <- forecast(x, h = test_size)
                                                        return(x)}))

# measures the accuracy of all forecast models against the test set
acc <- lapply(forecasts, function(f) accuracy(f, test)[2,,drop=FALSE])
# remove Theil's U (in case it exists) from matrix
removeTheil <- function(mat) {
  rows <- rownames(mat)
  cols <- colnames(mat)[1:7]

  m <- matrix(mat[,1:7], ncol = 7)
  rownames(m) <- rows
  colnames(m) <- cols
  return(m)
}

acc <- lapply(acc, removeTheil)
acc <- Reduce(rbind, acc)
row.names(acc) <- NULL
acc <- as.data.frame(acc)
# Adds a column to acc to indicate the model name of the forecast row.
# Depending the characteristics of the time series object, the hybridModel()
# outputs nothing, which makes acc object have 17 instead of 18 rows.
# Therefore, the line below is necessary to handle this situation
acc$model <- if (nrow(acc) == 18) available_models else available_models[-18]

# Selects row of minimum error. In case the error defined is MAPE and the
# time series is intermitent, the MAPE might be Inf. To handle this, if MAPE
# is Inf in all columns, it uses MAE as the error metric to select the best
# forecast model.
acc <- na.omit(acc) # some times stlm models produces NA.
rownames(acc) <- seq(1, nrow(acc), 1) # fixes na.omit() bug with rownames
ind_best_model <- if (mean(acc[[error]]) != Inf) which.min(acc[[error]]) else

```

```

which.min(acc[["MAE"]])
  best_model_name <- acc$model[ind_best_model]
  acc$best_model <- best_model_name

  # Applys apply_selected_model using the best forecast model from the previous lines
  best_forecast <- forecast(apply_selected_model(x, best_model_name, horizon), h = horizon)

  best_training_forecast <- apply_selected_model(training, best_model_name, horizon = test_size)
  best_training_forecast <- forecast(best_training_forecast, h = test_size)

  ### =====
  # creates data.frame to output the forecast from the best model
  df_comparison <- data.frame(
    time = Epi::as.Date.cal.yr(time(test)),
    forecasted = as.numeric(best_training_forecast$mean)[1:test_size],
    observed = as.numeric(test)
  )


  return(
    list(
      df_models = acc,
      best_forecast = best_forecast,
      df_comparison = df_comparison)
  )

}

```


APÊNDICE B – AJUSTE DE MODELOS NA SÉRIE TEMPORAL DO PRODUTO P001

Figura 10 - Ajuste e previsão obtidos pelo método ARIMA




Fonte: Autoria própria

Figura 11 – Ajuste e previsão obtidos pelo método de suavização exponencial




Fonte: Autoria própria

Figura 12 – Ajuste e previsão obtidos pelo método de redes neurais




Fonte: Autoria própria.

Figura 13 - Ajuste e previsão obtidos pelo método TBATS




Fonte: Autoria própria.

Figura 14 - Ajuste e previsão obtidos pelo método BATS




Fonte: Autoria própria

Figura 15 – Ajuste e previsão obtidos pelo modelo estrutural




Fonte: Autoria própria.

Figura 16 – Ajuste e previsão obtidos pelo modelo da média simples




Fonte: Autoria própria.

Figura 17 – Ajuste e previsão obtidos pelo modelo ingênuo.




Fonte: Autoria própria.

Figura 18 – Ajuste e previsão obtidos pelo modelo sazonal ingênuo.




Fonte: Autoria própria.

Figura 19 – Ajuste e previsão obtidos pelo modelo do passeio aleatório




Fonte: Autoria própria

Figura 20 – Ajuste e previsão obtidos pelo modelo do passeio aleatório com deriva




Fonte: Autoria própria

Figura 21 – Ajuste e previsão obtidos pelo modelo das *splines* cúbicas.




Fonte: Autoria própria.

Figura 22 – Ajuste e previsão obtidos pelo modelo Theta




Fonte: Autoria própria.

Figura 23 - Ajuste e previsão obtidos pelo modelo Croston




Fonte: Autoria própria.

Figura 24 - Ajuste e previsão obtidos pelo modelo de regressão



Fonte: Autoria própria.

Figura 25 - Ajuste e previsão obtidos pelo modelo híbrido



Fonte: Autoria própria.